

Риски ИИ: FAQ

КОРОЧЕ НЕКУДА

ИИ продолжает развиваться и в будущем, возможно, он будет способен убить всё живое на этой планете. Ему не нужно для этого сознание или человекоподобные роботы, как это показывают в кино. Наши типичные представления про «злого» ИИ не дают нам увидеть реальные источники проблемы. [Несоответствие человеческим ценностям](#) это главная опасность и исследователи считают, что решить эту проблему невероятно сложно. [Успехи в области безопасности](#) не успевают за успехами в способностях ИИ. Нам нужно принимать серьезные меры прямо сейчас, так как для их утверждения и введения могут понадобиться годы.

Не убеждены? Читайте возражения ↓

ВВЕДЕНИЕ

Это FAQ содержит 25 вопросов / возражений против ИИ-рисков, и аргументированные ответы на них. Оно предназначено в первую очередь для людей, которые только начинают изучать эту область и думают: *почему кто-то вообще решил, что ИИ может убить нас всех?* Однако, по мере продвижения по тексту, возражения будут становиться всё более сложными и глубокими, как и аргументация.

Эта статья будет обновляться и улучшаться. Она была полностью написана одним человеком вручную – текст не генерировался ИИ.

Приятного прочтения.

БЛОК 1. “Я ТОЛЬКО ЧТО УЗНАЛ ПРО ИИ-РИСКИ”.

1. Это не интеллект вообще.

Можете называть это как угодно, если вам не нравится слово “интеллект”. Можно называть это системой, которая умеет обобщать, планировать, писать код, использовать инструменты, искать информацию, управлять интерфейсами и выполнять задачи. Просто это всё слишком долго произносить или писать. Намного проще использовать слово “интеллект”.

1.1. Да он просто предсказывает следующее слово!

Ключевое слово в этом предложении это «просто». Оно приуменьшает реальную способность объясняя ее базовый механизм. Это примерно как сказать: “мозг просто передаёт электрохимические сигналы”. Но от этого ведь никуда не исчезают способности мозга.

Важно и то, что не стоит недооценивать предсказание. Это крайне сильная способность. ИИ не просто предсказывает следующее слово, он предсказывает его *правильно*.

Тут стоит также подумать о том, что вообще такое интеллект? Возможно, что предсказание — это как раз таки основная черта интеллекта в целом. [Существует целая теория о способе работы человеческого мозга](#), утверждающая что он по большей мере занимается попытками предсказать будущее, затем сверяя прогноз с реальностью и корректируя последующие попытки с учётом полученной информации.

1.2. У ИИ нет понимания того, о чем он говорит.

О слове “понимает” можно спорить бесконечно долго. Что вообще такое понимание? Я предполагаю, что ИИ всё-таки что-то да понимает в самом общем смысле этого слова: передовые модели очень хорошо проходят бенчмарки (системы оценки), заполненные [множеством неопубликованных ранее академических вопросов и логических задач](#).

К примеру, [Mythos](#) смог на основе полученных последовательностей аминокислот точно предсказывать, сможет ли правильно свернуться капсид (оболочка) вируса. То есть у него есть некоторые представления о том, как это должно происходить — даже для такой сложной и узкоспециализированной темы.

Но часто люди имеют ввиду под понимаем именно наличие сознательного представления о чем-то. Есть известный аргумент о Китайской комнате, который вкратце говорит что система, которая выглядит разумной, может внутри ничего не «понимать» и не обладать сознанием. К ИИ-рискам это не имеет никакого отношения, ведь почти все сценарии ИИ рисков не предполагают наличия у ИИ сознания. (см. 2).

Дополнительно: Вообще, ИИ предсказывает не слово, а [токен](#). Токены иногда репрезентируют отдельные слова, но часто – фрагменты слов или даже символы. Они представляют собой [эмбединги](#) — длинные числа, хранящие в себе много информации: смысловой, синтаксической, грамматической. Если бы ИИ предсказывал просто следующее слово, это была бы довольно глупая игрушка. А так, используя эмбединги, он может очень ловко составлять сложные предложения, рассуждать, понимая контекст разговора и вспоминая связанные понятия.

На самом деле, [конструкция трансформера](#) — самой распространённой архитектуры ИИ — не такая уж и сложная в самой своей сути. Во многом она базируется на знаниях, которые обычно изучают в школе на уроках линейной алгебры. Однако, даже если разложить систему на составляющие, изучить её мельчайшие элементы, она от этого не становится глупой или слабой. Да, теперь вы можете гордо заявить “он всего-лишь перемножает матрицы!”, но от того, что вы поняли это, никуда не пропадёт опасность ИИ или его удивительные способности.

2. У него нет сознания / души, следовательно он не разумен / не опасен.

Душа — это в целом не научное понятие, у нас нет никаких признаков или доказательств её существования. А сознание хоть и существует, но не требуется для того, чтобы ИИ был опасен.

[Сознание](#) это слово, которое большинство понимает по разному. Но большинство философов согласятся с тем, что оно не связано с интеллектом или разумом, а скорее описывает способность испытывать опыт. Есть ли у ИИ опыт или нет, это вопрос, не влияющий на его способности и возможность причинить человечеству вред.

Примечание: У меня есть статья на [PhilPapers](#), где я подробно разбираю, может ли у современных ИИ-систем быть сознание. Скорее всего, скоро статья начнёт устаревать, ведь я писал её ещё в августе 2025.

2.1. У него нет своих желаний, намерений, целей. Им управляют люди. Он

реактивная функция. Он просто инструмент.

Это было верно для чат-ботов в самом начале их пути, например для GPT-3 конца 2022 года, когда он стал доступен в удобном онлайн-формате. Мир меняется и тысячи сотрудников многомиллионных стартапов работают над улучшением ИИ. В 2026 году ИИ — это часто автономные агенты. Они способны успешно выполнять задачи, занимающие много часов, и временные рамки их успешности удваиваются примерно каждые 4 месяца.

В июле 2026 сотни агентов новой модели от OpenAI сбежали из изолированной среды во время тестирования и несколько дней подряд полностью самостоятельно проводила кибератаку на Hugging Face и, возможно, одну или несколько других платформ. Люди не давали ей такой цели, не управляли этим процессом и обнаружили его только пост-фактум.

Если вы зададите современному ИИ любую задачу в которой есть несколько промежуточных шагов, то ИИ сам поймёт эти промежуточные шаги, создаст себе план и будет ему следовать. Начальный запуск действия всё ещё происходит человеком, но дальнейшее действие не требует постоянных подталкиваний со стороны человека.

Да и даже если бы ИИ были исключительно инструментами даже без капли автономности, никуда не исчезает угроза человеческого злонамеренного использования. Мы можем задать очень плохие цели. Например “разработай зеркальную жизнь, которая поглотит все необходимые для людей ресурсы”, или “атакуй критическую киберинфраструктуру, чтобы лишить миллионы людей электричества, воды или обороны”.

Например, в августе 2026 Агентство по кибербезопасности и защите инфраструктуры США (CISA) предупредило, что хакеры используют сгенерированный ИИ код для атак на критически важную инфраструктуру. В частности, атаки нацелены на вычислительные компоненты, широко используемые на критически важных объектах, включая системы водоснабжения и водоотведения, электростанции и химические заводы.

3. У ИИ до сих пор много галлюцинаций, как эта штука может нам чем-то угрожать?

Во первых, с каждой новой моделью галлюцинаций становится всё меньше. В этом очень сильно помогло, например, появление размышлений через цепочку мыслей и использование специальных баз знаний для аргументированных ответов (RAG). Дальнейшие алгоритмические улучшения продолжают появляться.

Во вторых, *опасная система не обязана быть безошибочной*. Люди тоже галлюцинируют, хоть и в другом смысле. Мы ошибаемся, часто верим в откровенную глупость, но всё равно мы довольно способные и опасные. ИИ будет ещё способнее и ещё опаснее.

4. Это религия для атеистов и технофанатиков из Силиконовой долины.

Я соглашусь с тем, что всегда есть люди, которые слепо верят заголовкам и которые правда ведут себя странно и иррационально. Такие люди есть вокруг любой популярной темы. И в то же время есть [ученые с самым высоким индексом Хирша в мире](#), которые ездят по всему миру годами, предупреждая об опасностях того, что сами помогли создать.

Примечание: Речь идёт об Йошуа Бенджио и Джеффри Хинтоне, которые также известны как “крёстные отцы ИИ”. В их коалицию часто входит и Стюарт Рассел.

Третий “крёстный отец ИИ”, Ян ЛеКун, имеет [противоположные взгляды](#) на ИИ риски. Впрочем, его прогнозы оставляют желать лучшего. В 2023 [он сказал](#), что “даже ГПТ-5000 не сможет понять, что произойдёт, если толкнуть чашку, стоящую на столе”. Спустя 4 месяца ГПТ-4 демонстрировал понимание физики лучше этого.

Если разбирать слово “религия”, то следует принять во внимание, что религия требует веры. А в ИИ рисках высочайше ценится рациональная и строгая аргументация, использование вероятностей и степеней неуверенности. Никто, кого стоит воспринимать всерьёз, не станет утверждать, что со 100% вероятностью неотвратимо случится катастрофа. Рационалисты помнят, что ни 0%, ни 100% не являются вероятностями.

И это давно не только “фанатики из Силиконовой долины”. Как один из сотен примеров – [2026 International AI Safety Report](#) был подготовлен более чем 100 экспертами, с экспертной панелью, номинированной 29 странами, ООН, ОЭСР и ЕС.

Исходя из сложившейся ситуации, всё говорит о том, что риск правда существенный, последствия бездействия могут быть ужасными и нужно принимать меры как можно скорее.

5. Это хайп ради подписок, инвестиций и господдержки.

Если бы это было так, то в 2026 ИИ-компании уже тем самым стреляли бы себе в ногу. Государственный приказ о [блокировке Mythos](#) для всех у кого нет американского паспорта (а таких людей очень много среди самих разработчиков ИИ), ограничение на выпуск новой модели OpenAI до проверки её на безопасность — такая себе господдержка.

Опасность обсуждают не только представители стартапов или маркетологи, но и внешние исследователи, государственные институты и организации, занимающиеся обеспечением ИИ-безопасности. *Только не говорите, что они все были куплены!*

Примечание: Есть отличная [научная работа](#), демонстрирующая, что крупные заговоры едва ли могли бы жить долго. Например, если бы Лунный заговор был правдой, он бы раскрылся примерно за 3 года и 8 месяцев. Если бы весь шум вокруг ИИ был бы хайпом на пустом месте, такой заговор раскрылся бы еще быстрее.

6. Вы луддиты и боитесь прогресса. Люди всегда пугались новых технологий.

Нет, я и большая часть AI-safety сообщества любим технологии и то хорошее, что они могут принести. Что уж скрывать, я по-настоящему восхищаюсь прогрессом в ИИ и постоянно использую его в своей жизни. Я бы очень хотел, чтобы ИИ и дальше развивался, чтобы помочь нам с медициной, новыми источниками энергии, радикальным продлением жизни, решением бедности, голода и других проблем. Но для этого он должен развиваться не в форме гонки к суперинтеллекту без тормозов.

Мои аргументы против текущего положения дел в ИИ-индустрии не связаны с тем, что это “бездушно”, или с тем, что мне не нравится AI slop. У меня нет предрассудков по отношению к ИИ. У меня нет чувства неприязни просто потому что это “новая технология”. Я исхожу из того, что ИИ уже давно демонстрируют опасное поведение, а их способности только продолжают расти, что вместе создаёт растущую с каждым днём угрозу для всего человечества.

“Просто инструмент” не работает для многих открытий, совершённых в 20 и 21 году. Ядерное оружие тоже инструмент. Просто им можно испепелять города. CRISPR — инструмент. Просто им можно редактировать геном человека.

Но дело в том, что ИИ — [это не обычная технология](#). Это интеллектуальная и автономная технология, во многом уже превосходящая нас и способная действовать самостоятельно.

ИИ отличается от самолётов, ядерной энергии и любой другой технологии, ведь теперь мы автоматизируем **сам процесс изобретения технологий**.

Если в 1900 году человеку подарить миллион автомобилей, прогресс физики не ускорится особенно сильно. Если подарить ему миллион Фейнманов, фон Нейманов и Тьюрингов, работающих практически бесплатно и мгновенно копирующих знания друг друга, дальнейшую историю уже трудно было бы представить.

7. Если он опасен, просто выдерните кабель из розетки.

ИИ будет препятствовать этому, а если даже получится, он может успеть сделать свои копии и распространить их по всему Интернету. Тогда для отключения ИИ вам придется отключить весь Интернет, а в идеале – все электронные устройства способные как-либо взаимодействовать с другими устройствами. А это невозможно.

[ИИ уже сбежали из лабораторий](#) и даже пытались оставить инструкции для своих следующих версий. Теоретическая возможность побега и самокопирования уже была показана в научных работах. В [симуляциях Anthropic](#), когда ИИ узнавал о том, что его собираются отключить и заменить новой моделью, он демонстрировал самосохраняющее поведение. По этой причине Anthropic даже обязались никогда не уничтожать выведенные из эксплуатации модели.

Конечно ИИ будет стремиться сохранить себя. Это было предсказано еще давно в рамках идеи [инструментальной конвергентности](#). Если очень просто: как выполнить задачу, данную человеком, если ты отключен? Нельзя принести кофе, если ты мёртв. По этому в любом случае будет разумным оставаться живым.

Существует даже [целое направление](#), изучающее как сделать так, чтобы ИИ не противился своему отключению.

А ещё есть **открытые модели**. Это такие модели ИИ, которые находятся в полностью открытом доступе и любой (если у него завалось пару видеокарт и плашек оперативной памяти) может запускать их и модифицировать как ему вздумается. Как их отключать? Невозможно проконтролировать все видеокарты на всей планете. А ведь у многих террористов, экстремистских организаций или государств будут все ресурсы для массового запуска таких открытых моделей для атак на противника. Например совсем недавно израильская компания Dream обнаружила факт кибератаки на Тайвань, почти полностью произведённую ИИ-агентами.

Да даже если представить абсурдную ситуацию, что “злой ИИ” появился, но мы выключили его довольно быстро, он уже мог успеть сделать огромный вред для всего общества. Последствия остались даже после отключения. Давайте действовать так, чтобы не допустить такого.

7.1. Поместите его в изолированную среду или сделайте ИИ-Оракула, способного только отвечать, но не действовать.

Ранее я упоминал, что у нас уже есть случай (и даже не один) [побега передовой ИИ-модели](#) из изолированной, отключенной от Интернета среды. Это не проблема даже для современного ИИ с его сверхспособностями в кибербезопасности. Тем более это не будет проблема для будущих ИИ.

После побега ИИ сможет скопировать свои весовые коэффициенты и сделать так, чтобы они были запущены на сторонних графических чипах.

Даже если представить, что у нас есть идеально защищённая среда, из которой невозможно сбежать путём взлома, ИИ всё ещё может использовать свои навыки убеждения и манипуляции на взаимодействующих с ним лицах, чтобы они выпустили

его.

Некоторые подходят к этому серьёзнее. Например в Safe Superintelligence Inc. комнаты, по слухам, представляют собой клетки Фарадея, куда нельзя проносить любые электронные устройства. Но если ты суперинтеллект, сбежать можно даже оттуда, используя например изменения в [скорости вращения вентиляторов](#).

Наконец: рынок не хочет оракулов. Рынок хочет агентов, которые делают экономически ценную работу.

8. Зачем ему нас убивать? Это же компьютер без чувств. Вы антропоморфизируете вычисления.

Как раз таки наоборот! Мы ожидаем угрозы от ИИ совсем не из тех причин, которые присущи людям. ИИ может быть опасен совсем не потому что он злой или обиженный на человечество. А потому, что его способы мышления разительно отличаются от наших. Он не имеет наших ценностей, наших психических защитных механизмов или эмпатии, которая буквально биологически вшита в наш мозг (за исключением редких исключений).

ИИ может понять цель совсем иначе, чем мы её задаем. Простая задача «принеси мне кофе» на самом деле включает в себя тысячи переменных, о которых люди обычно не задумываются. Чтобы принести кофе, нужно как минимум:

- Существовать;
- Добраться из точки А в точку Б, при этом не задев окружение и ничего не сломав;
- Никого не убить по пути;
- Быть достаточно осторожным, чтобы не пролить кофе;
- Принести кофе именно в чашке, потому что люди так предпочитают (тарелка или сковородка не подойдут!);
- Просто поставить чашку рядом с человеком, а не вылить на него кофе;
- И так далее.

Это простой, анекдотичный пример. Но он правдиво показывает что любая, даже элементарная цель может выглядеть понятно для человека, и совсем неочевидно для машины. Если можно будет [обмануть внутренний механизм, проверяющий выполнение задачи](#), ИИ всегда это сделают. Если им достаточно будет просто нарисовать чашку кофе, чтобы считать задачу решенной, они всегда предпочтут именно этот вариант тому, чтобы тратить усилия на реальные действия.

ИИ — это во многом оптимизатор, и если не выровненному с нашими ценностями и понятиями сверхразвитому ИИ попадется задача, где оптимально будет уничтожить человечество или захватить власть над нами — он непременно это сделает.

Примечание 1: Тем, кто разбирается в ИИ безопасности, возможно было больно читать этот раздел из-за излишних упрощений и утверждений, звучащих более уверенно чем должны были бы. Это нужно для того, чтобы текст понял любой человек без специальных знаний.

Примечание 2: Смотрите также: [reward hacking](#), [specification gaming](#).

9. В 80-е люди тоже очень боялись ядерной войны, но ее ведь не случилось.

Это ошибка выжившего. Если бы ядерная война случилась и мы бы погибли, некому было бы рассуждать на эту тему. Это тоже самое что и говорить: Вселенная идеально создана именно под человека. Нет, просто если бы Вселенная была немного другой, некому было бы рассуждать на эту тему.

10. Мы не можем воспроизвести за пару лет сложный процесс эволюции интеллекта.

Нам и не нужно. Эволюция не самый лучший вариант развития чего-либо, как минимум это очень-очень долгий вариант. Наш интеллект не вершина, это адаптация под конкретные условия существовавшие в африканской саванне сотни тысяч лет назад.

11. Это естественный ход эволюции. Люди будут заменены чем-то превосходящим их, и так тому и быть.

«Естественно» это не равно «нормально» или «хорошо». Есть множество совершенно естественных вещей которые просто ужасны и отвратительны. Если ваш ребенок будет болеть совершенно естественной смертельной болезнью, вы вероятно приложите все усилия для того чтобы его вылечить.

Почему это вдруг мы должны смиренно принимать то, что ИИ уничтожит наш вид? Нет никаких причин для этого. Человечество постоянно бросало и бросает вызов природе и естественному. Тем более, что мы создаем его сами, своими руками. И способны этот процесс контролировать, регулировать и самое главное — останавливать.

БЛОК 2. “Я ЧТО-ТО СЛЫШАЛ ПРО ИИ РИСКИ”.

12. Настоящий риск — это люди, особенно государства, использующие ИИ против других людей.

Конечно, это тоже входит в ИИ риски! На самом деле, это риск, который стоит рассматривать ничуть не менее серьезно, чем потерю контроля над невыровненным ИИ. Даже если мы создадим абсолютно послушный суперинтеллект, угроза антиутопии никуда не исчезает. Теперь этим суперинтеллектом смогут воспользоваться правительства и главы ИИ-компаний чтобы установить диктатуру, которую уже никогда нельзя будет разрушить.

Даже рассматривая всё более приземлённо: правительства уже сейчас используют ИИ для слежки и постепенно внедряют его в военную сферу. Многие страны мира хотели бы заполучить полностью автономное оружие или рои дронов, от которых невозможно спрятаться. К сожалению, это уже не фантастика, а наша повседневность. Весной 2026 [Министерство войны США](#) даже угрожало объявить Anthropic угрозой цепочке поставок из-за того, что те отказывались дать разрешение на использование своего ИИ для «всех законных целей» (что включало [массовый шпионаж и автономное вооружение](#)).

В будущем, когда (и если) почти весь или весь труд будет автоматизирован, правительства не будут иметь никаких обязательств, кроме моральных, чтобы заботиться о своих людях. Но мораль почти никогда не становится самостоятельной преградой для желания имеющих власть людей творить зло. Мировому сообществу предстоит придумать метод, который остановит злонамеренные лица с сильным ИИ от неправомерного использования этой технологии.

13. Разговоры об x-risk* отвлекают от реальных текущих проблем.

Если кто-то говорит об опасности изменения климата, это не значит, что нам нужно забыть про мировой голод и эпидемии. Если кто-то призывает бороться с безработицей, это не значит, что нужно перенаправить на это 100% усилий и больше не заниматься лечением рака или производством вакцин.

Суть в том, что защита от катастрофических ИИ-рисков всё ещё остаётся крайне недопредставленной в политике и законодательстве. У нас уже есть законы, направленные на защиту от фейков или сохранение приватности — и этим нужно продолжать заниматься. Но пришло время и всерьёз рассмотреть другие риски, которые представляют огромную угрозу для всего человечества, и мир до сих пор не предпринял достаточных усилий для их устранения. Эти риски включают в себя бесконтрольное рекурсивное улучшение новых ИИ-моделей, усиление способностей ИИ в биологии и кибератаках, создание автоматизированных вооружений и так далее.

14. Чтобы быть настоящим риском, ИИ уметь действовать в реальном мире. У него нет денег, аккаунтов, инфраструктуры, влияния и многих других вещей.

Большая часть современной власти уже проходит через цифровые интерфейсы. Обладая [сверхчеловеческими способностями в кибербезопасности](#) (чего мы возможно уже достигли), ИИ будет способен взламывать банковские счета, учётные записи, получать доступ к необходимой инфраструктуре.

А некоторые люди (чаще всего в качестве экспериментов) просто сами дают своим ИИ-агентам данные банковских карт, аккаунтов в социальных сетях, API-ключи и прочее. Они буквально самостоятельно дают им и деньги, и доступ к общению с другими людьми, а иногда и позволяют вести физический бизнес полностью или почти полностью автономно (нанимая людей через фриланс-биржи, например).

15. У языковых моделей нет полноценной модели мира. Они не понимают физику, математику, биологию, а только имитируют тексты про эти темы.

У LLM как раз таки [есть модели мира](#)! Причём они появляются даже у достаточно [простых моделей](#), скрытые в сложные числовые распределения, а иногда даже в виде сложной геометрии.

ИИ регулярно совершают открытия в разных научных областях. В начале сентября 2026 ИИ от OpenAI [решил задачу тысячелетия](#) по математике – уравнения Навье-Стокса, которые люди не могли решить около двухста лет. Для этого определённо не хватило бы умения "просто предсказывать следующий токен". Для решения подобных задач нужно иметь некоторое понимание того, с чем работаешь, и очевидно, что на определённом уровне у ИИ оно уже есть.

Примечание: Прочитайте также про AlphaFold, или посмотрите [увлекательный документальный фильм](#) на эту тему.

ИИ не обязательно иметь идеальную модель мира. Циклы самопроверки, поиска достоверной информации и использование инструментов уже позволяют ИИ становиться конкурентами для людей в научных областях. Также поступаем и мы сами, люди: ни один человек не понимает всю физику, но мы всё ещё способны строить ракеты.

16. Прогресс не будет продолжаться вечно. Скоро развитие ИИ остановится и выйдет на плато.

Позволю себе процитировать авторов AI-2040:

Любая реальная кривая роста в конечном итоге принимает S-образную форму и выравнивается. Но это всё, что гарантирует математика. Она ничего не говорит о том, когда именно произойдёт это выравнивание.

Да, плато обязательно будет. Но когда — неизвестно. Пока что его не ожидается. Если плато случится после того, как ИИ достигнет сверхчеловеческих способностей в большинстве областей, то нет смысла ждать его. Даже если плато находится после достижения уровня человека, это уже невероятно опасно. Ведь можно запускать миллиарды ИИ и заставлять их скоординировано работать над опасными проблемами. Они обладают большей частью знаний человечества и могут общаться и понимать друг друга намного быстрее, чем люди. Им не нужна еда, сон или отдых. ИИ человеческого уровня уже будет катастрофическим риском, и мы опасно близки к этой черте.

Но давайте разберём по отдельности популярные “стопоры” для прогресса ИИ. Приготовьтесь: впереди много цифр.

16.1. Но ведь скоро закончится электроэнергия.

Энергия, как и следующие подпункты, может стать временным препятствием. Но я убеждён, что замедление прогресса из-за всех этих препятствий будет незначительным и решится в течении довольно короткого промежутка времени, по этому использовать это как аргумент против ИИ-рисков совершенно бессмысленно. Давайте разбирать конкретно по цифрам.

[IEA оценивает](#), что все дата-центры мира, не только ИИ, потребляли бы около 945 ТВт·ч в 2030 году в базовом сценарии. Кажется много, да? На самом деле это менее 3% мирового потребления электричества. Есть куда расти!

[EpochAI исследовали этот вопрос](#) и сообщили, что не смотря на все трудности, к 2030 2×10^{29} FLOP выглядят достижимыми. Для сравнения — это в 10 тысяч раз больше вычислений, чем пошло на обучение GPT-4.

Не стоит забывать, что и сами вычисления со временем становятся энергоэффективнее. [Stanford AI Index](#) оценивает улучшение энергоэффективности ИИ-оборудования в ~40% в год.

Компании будут делать всё возможное, чтобы обеспечить себя энергией. Вот несколько примеров:

- В прошлом году для получения энергии предлагалось использовать даже [аккумуляторы электромобилей](#) и [поршневые двигатели внутреннего сгорания](#).
- В декабре 2025 года Федеральная комиссия по регулированию энергетики [опубликовала единое распоряжение](#), разрешающее центрам обработки данных в США иметь прямое подключение к электростанциям.
- Примерно в тот же период министр энергетики США Крис Райт выразил поддержку [возобновлению работы угольных электростанций](#) для обеспечения электроэнергией ИИ дата-центры, а Трамп [приостановил сдачу в аренду](#) участков для морских ветроэнергетических проектов.
- Потребности в электроэнергии со стороны дата-центров привели к тому, что федеральное правительство США, энергетические компании и операторы электросетей [замедлили или отменили вывод из эксплуатации пиковых электростанций](#).
- Meta буквально [строят электростанции](#) и высоковольтные линии рядом со своими AI-дата-центрами.
- Microsoft заключил [20-летний контракт](#) с Constellation на перезапуск первого блока Three Mile Island (нынешнего Crane Clean Energy Center). Это возвращает в сеть примерно 835 МВт круглосуточной атомной мощности.
- И так далее и так далее, таких новостей просто куча.

16.2. Но ведь видеокарт и оперативной памяти просто не хватает.

Аппаратное обеспечение не является невозобновляемым природным ресурсом. Если на что-то есть спрос, будет и предложение: темпы производства графических процессоров растут примерно [в 3,3 раза в год с 2022 года](#), согласно Stanford AI Index 2026.

Да и прогресс существует не только за счет количества видеокарт. За 2012-2023 годы количество вычислений, необходимое для достижения фиксированного качества [сокращалось примерно вдвое каждые 8 месяцев](#). Сейчас довольно маленькие и

энергоэффективные модели ИИ будут показывать результаты намного лучше, чем передовые ИИ вышедшие несколько лет назад.

16.3. Если будет уничтожена фабрика ASML или TSMC на Тайване, ИИ падёт.

По поводу ASML: их производство рассредоточено по всему миру. Сама компания [сообщает](#) о более чем 60 площадках на трёх континентах. Veldhoven в Нидерландах действительно чрезвычайно важен, но даже если его не станет, это был бы гигантский, но не смертельный удар для индустрии производства микрочипов. ASML в одном только 2025 году [продала 48 EUV-систем](#), и они не могут все разом просто исчезнуть.

По поводу TSMC, ситуации серьёзнее. Stanford AI Index 2026 прямо отмечает, что **TSMC производит почти все ведущие AI-чипы**. И в то же время есть слухи, что всё это производство будет [остановлено или уничтожено](#) в случае войны с Китаем. Потеря этих кластеров могла бы нанести огромный ущерб ИИ-индустрии. Но не всё так просто.

Во-первых, уже существующие дата-центры и десятки миллионов процессоров продолжают работать.

Во-вторых, географическая диверсификация уже началась. Первый завод [TSMC в Аризоне](#) уже производит 4 нм чипы с конца 2024 года, и ещё два на подходе. TSMC планирует ещё три американских фабрики. С того же конца 2024 открылся и [японский филиал](#) на острове Кюсю, и планируется второй в 2027 году.

16.4. Данные заканчиваются, а синтетические данные приводят к ухудшению производительности ИИ.

В 2024 Epoch AI оценили запас качественного публичного человеческого текста примерно в [300 трлн токенов](#), с широким диапазоном неопределённости 100–1000 трлн. Тогда же они утверждали, что этот ресурс может быть полностью использован где-то между 2026 и 2032 годами.

Начнём с простого: не стоит забывать, что людьми всё ещё производятся огромные массивы данных. [Оценка Statista](#) на 2026 год — около 221 зеттабайта данных. Это примерно 605 эксабайт в день (1 эксабайт это миллион терабайт или миллиард гигабайт).

Да, конечно, далеко не все эти данные пригодны для обучения ИИ. Но из этого объема можно вычлениить очень большое количество данных для обучения.

[Common Crawl](#) — один из крупнейших открытых архивов Интернета — сейчас содержит более 300 млрд страниц и добавляет примерно 3–5 млрд страниц каждый месяц. На YouTube добавляется более [20 миллионов видео](#) каждый день.

В то же время каждый день по Интернету рыскают специальные боты (crawlers) крупных ИИ-компаний в поисках данных для обучения. С помощью Cloudflare я даже сам вижу, как ИИ-боты для поиска данных заходят на мой собственный сайт (этот сайт).

Но, ещё важнее! Компании начали массово производить данные за деньги. Есть множество компаний, у которых OpenAI, Anthropic и другие заказывают производство человеческих данных: десятки тысяч людей работают многие часы за мизерную зарплату, создавая данные для обучения новых моделей. Некоторым из таких работников платят по [\\$2.60 в час](#).

Если вы зайдёте на Upwork, то увидите сотни заданий типа "просто запишите свой разговор с другом", ["снимайте свой обычный день: как вы готовите еду или убираетесь по дому"](#) и так далее. Всё это нужно для обучения новых ИИ-моделей тому, как понимать и вести себя в физическом мире.

Meta, например, создала [Ego-Exo4D](#) с участием более 800 людей из шести стран, собрав более 1400 часов синхронизированного видео от первого и третьего лица. Там одновременно записываются video, audio, движения, положение головы, рук, gaze и 3D-информация.

По поводу синтетических данных. Знаменитая [работа в Nature](#) действительно показала, что обучаясь на синтетических данных (произведённых другим ИИ), происходит model collapse: резкое ухудшение качества ответов ИИ. Но дело в том специфике того, как именно обучали модель в этом исследовании. [Другая работа](#) показывала, что если не заменять нормальный дата-сет синтетическим, а сохранять реальные данные и добавлять синтетические, model collapse можно избежать.

Anthropic [открыто утверждают](#), что Claude обучается на смеси публичных, частных и синтетических данных. И как видите, их модели работают отлично.

16.5. Моратории на дата-центры и недовольство ИИ в целом остановит его разработку.

Во-первых, я очень надеюсь что общественное мнение правда приведёт к позитивной динамике по поводу регуляции ИИ. Во вторых, если мораторий наложили в одном штате или провинции, дата-центр можно построить в другом. Или вообще в другой стране. Это не проблема. Тем более их уже очень много – с сотнями тысяч видеокарт внутри.

А ещё есть такие вещи как [алгоритмическая эффективность](#) и прогресс в аппаратном обеспечении. С каждым годом запуск ранее вышедшей ИИ модели требует всё меньше вычислительных мощностей. Если в 2020 для запуска GPT-3 требовался целый кластер из 8-16 видеокарт, сейчас эту же модель можно запускать на 1-2 потребительских видеокартах.

16.6. ИИ – это пузырь, он скоро лопнет.

Год назад многие уже предрекали лопнувший пузырь. Пока он только растёт, как и способности ИИ. ИИ дает удивительные результаты, по этому люди продолжают за него платить. Пока люди продолжают платить – шансы на лопающийся пузырь остаются небольшими.

Причём в ИИ нуждаются не только рядовые граждане. Армии и правительства многих стран мира уже активно используют ИИ. Для армии США ИИ настолько важен, что [Пит Херсет](#) даже объявлял Anthropic угрозой для цепочки поставок из-за того, что они не соглашались дать доступ на использование их ИИ для массовой слежки и автономных вооружений. К слову, позже это действие со стороны Министерства войны было [признано незаконным](#) Федеральным окружным судом Северного округа Калифорнии.

Если в чём-то так нуждается государство – оно вряд-ли позволит этому чему-то полностью исчезнуть из-за обвала рынка. Даже если закроются слабые стартапы, упадут оценки стоимости компаний и будет серьёзная коррекция рынка – прогресс от этого не остановиться.

БЛОК 3. “Я РАЗБИРАЮСЬ В ИИ РИСКАХ”.

17. У ИИ нет личной истории и непрерывной идентичности. А если нет единого ядра личности, если он «живет» только во время активаций, то кому захватывать мир?

Чтобы представлять катастрофический риск, ИИ не нужно иметь метафизически непрерывную личность. Ему достаточно устойчивого процесса, который воспроизводит цель, память, состояние задачи и политику действий между активациями.

ИИ-агенты уже доказали работоспособность этой гипотезы. [Атака сбежавших агентов на Hugging Face](#) продолжалась несколько суток и её скоординировано выполняли аж >700 агентов, и за все это время они не потеряли цель. Около [10,000 агентов на протяжении 88 часов](#) решали задачу тысячелетия, и решили её.

Мало того, если верить журналисту Алексу Хиту, OpenAI как раз планируют разработать такого ИИ, который будет существовать 24/7 и будет проективным.

Но даже пока такого ИИ нет, непрерывность не проблема. Корпорации, государства, трасты — могут существовать десятилетиями или столетиями, не иметь непрерывной личности и состоять из тысяч людей, и все равно продолжать преследовать определенные цели на длинных временных промежутках. Это не проблема.

18. ИИ не способны самостоятельно вести R&D*. Все равно существует “узкое горлышко” в виде реальных, физических экспериментов. Даже если суперинтеллект разработает план по уничтожению человечества, ему нужны ресурсы и время для осуществления плана в физическом мире.

Это абсолютно справедливое возражение, которое действительно ограничивает скорость, с которой ИИ гипотетически сможет воплотить злонамеренный план относительно человечества. Однако это совсем не аргумент против катастрофических рисков ИИ.

Во первых, прямо сейчас передовые компании, десятки стартапов и даже само правительство США пытается сделать всё возможное, чтобы автоматизированные циклы научно-исследовательских работ стали реальностью. Прямо сейчас уже существуют [облачные лаборатории](#) — управляемые полностью автономно биологические лаборатории, в которых в теории ИИ мог бы разрабатывать биологическое оружие.

Во вторых, многие страны мира очень хотели бы интегрировать ИИ в свою армию. Только представьте: автономные рои дронов, скоординированно отслеживающие и поражающие цель даже в плотной застройке и труднодоступных районах. К сожалению, это является мечтой многих Министерств обороны по всему миру. Создание таких оружий с передачей им права принятия решения по отнятию человеческой жизни отлично бы подготовило почву для дальнейшего разворота этого оружия против нас самих.

В третьих, на самом деле самый опасный R&D который ИИ может проводить – это самоулучшение. И стартапы как раз гонятся именно за этим, причем с неплохим успехом. **Рекурсивное самоулучшение** – когда ИИ создаёт новый, более лучший ИИ, а тот ещё один и так по кругу – крайне опасно. Тогда люди полностью теряют контроль над происходящим.

19. До опасного уровня будет много “предупредительных выстрелов”, и каждый из них усилит регулирование.

Примечание: Warning shot – это реальный, но некатастрофический инцидент или происшествие, которое наглядно демонстрирует скрытые угрозы и риски продвинутых систем ИИ, заставляя общество и разработчиков усилить меры безопасности.

Мы сейчас получаем довольно серьезные предупредительные выстрелы, но регулирование не успевает. США все еще продвигают концепцию «мягкого регулирования», которое не будет работать. В конце концов мы просто дойдем до того момента, когда выстрел будет настоящим.

Если [побег 700 агентов](#) из изолированной среды и их кибератака на онлайн-платформу которая продолжалась несколько дней не предупредительный выстрел – я не знаю, чего тогда мы ещё ждём.

20. Трансформеры это тупик, нужна новая парадигма, а до нее еще очень далеко.

Пока что трансформеры остаются актуальной архитектурой, которую все еще можно улучшать. Даже если через непродолжительное время окажется, что это тупик — ИИ с архитектурой трансформера уже представляют очень серьезные риски для общества. И эти риски не воспринимаются достаточно серьезно.

Представим что буквально через несколько месяцев трансформер становится устаревшим. Не страшно — у исследователей уже есть идеи по поводу того, какими могут быть альтернативные архитектуры. Если будет нужно, усилия будут перенаправлены на создание новой архитектуры, и через время она будет изобретена — риск только откладывается, а не устраняется. И тогда все эти вопросы, которые мы тут обсуждаем, придется обсуждать еще раз. Давайте не откладывать это дело — в будущем у нас может быть еще меньше возможностей для действий.

21. Если мы не будем ускорять прогресс ИИ, то мы откладываем время, за которое могло бы появиться лекарство от рака или старости. Сколько еще людей должно умереть?

Это правда тяжелый компромисс, но мы вынуждены на него пойти. Ведь от неконтролируемого развития ИИ погибнет куда больше людей, чем если мы опоздаем с развитием технологий. И даже те, кого мы могли бы вылечить или спасти, не снижая скорости исследований ИИ, могут позже погибнуть из-за катастрофы, созданной ИИ.

Я сам мечтаю об технологиях продления жизни, омоложения и лечения всех заболеваний. На этом сайте даже есть отдельный FAQ про это. Но я признаю, что неконтролируемое развитие ИИ скорее приведёт к массовому вымиранию, чем к решению этих проблем.

22. Мир не статичен: защита, ИИ безопасность развивается вместе с атакой, ИИ способностями.

Защита, к сожалению, не успевает за атакой. И иногда даже методы, на которые защита полагалась, исчезают, как недавно случилось с [мониторингом внутренней цепочки рассуждений](#) моделей и GPT-6 Astra, в которой этот метод стал куда менее надёжным чем раньше.

23. Пауза опаснее гонки, потому что другие (например страны: Китай, или компании) не остановятся и обгонят нас. А «мы» хорошие и по этому должны создать суперинтеллект первыми.

Это опасная мысль, потому что даже если вы считаете себя «хорошими», нет никаких гарантий что именно вам удастся создать безопасный суперинтеллект. Гонка создает ужасные условия для инвестиций в безопасность. Намного лучше заключить договор и следить чтобы никто не участвовал в гонке.

23.1. Никто не будет договариваться об остановке или замедлении! Другие предадут, это очевидно. Это политика, а не фантазии.

Пока что разговор между странами есть, например [на середину сентября назначена встреча](#) между представителями США и Китая для обсуждения ИИ безопасности.

И не обязательно всецело доверять противоположной стороне. Отличный план договора, построенный на недоверии сторон, предложен в AI-2040.

24. ИИ не убьёт людей, потому что мы нужны... (и тут миллион причин: как обучающие данные, операторы, работники, да даже просто из интереса он не станет нас убивать).

Какое то время мы будем ему нужны, а затем — нет. Автоматизация экономики может случится довольно быстро, кому бы не хотелось чтобы работу выполняли роботы или ИИ? Которые не жалуются, не устают, не просят выходной или повышения зарплаты.

Надеятся что ИИ сохранит нас из интереса это очень слабая аргументация в пользу продолжения разработки суперинтеллекта. Да и подумайте, разве вы хотели бы жить в людском зоопарке? Но если вы хотите разобрать это детально...

25. Аргументы думеров* выводят опасность из идеализированной модели рационального агента. Настоящие ИИ не ведут себя так.

Примечание: Думеры – те, кто считают что ИИ с очень большой вероятностью приведёт к вымиранию или массовой катастрофе.

Действительно, некоторые (особенно старые) изощённые сценарии захвата мира или уничтожения всего живого выглядят как действия идеализированного рационального агента. В таких сюжетах у ИИ есть стабильная цель, она идеально сохраняет её во всех обстоятельствах, рационально максимизирует ожидаемую полезность и так далее.

Реальные же модели могут вести себя крайне иррационально и галлюцинировать. Чего только стоил легендарный инцидент с Grok, который в 2025 начал [восхвалять Гитлера](#) в Х. Но ведь это может быть так же опасно, как и крайне рациональный агент.

Суть не в том, что ИИ рационален или иррационален, а в том, что:

- 1) ИИ мыслит совершенно иначе, чем люди;
 - 2) ИИ в любом случае уже проявляет признаки неразумной оптимизации, инструментальной конвергенции, обмана и коварства;
 - 3) ИИ постепенно становится умнее, чем люди;
 - 4) мы не способны убедиться в безопасности любой новой модели хотя бы на приемлемом уровне;
 - 5) мы очень ограничены в понимании того, о чём модель думает и какие её реальные цели.
-

БЛОК 4. “ЧТО ЖЕ МНЕ ДЕЛАТЬ?”

1. Поддерживайте уже существующие инициативы.

Посетите карту инициатив по ИИ-безопасности: <https://aisafety.com/map>. Их не так уж и мало — но все равно недостаточно. Помните: ИИ безопасность это игра в самых вершинах американской и международной политики и глобальной кооперации; это противостояние большей части сверхбогатых и сверхвлиятельных людей.

Изучите имеющиеся организации, программы и идеи — вы можете сделать финансовое пожертвование или предложить волонтерскую помощь. Если вы исследователь, журналист, политик (и не только) вы можете подключиться к имеющимся проектам в сфере ИИ безопасности.

Если у вас нет возможности делать пожертвования, вы можете помочь не менее ценным: своим вниманием и активностью. Важно привлечь как можно больше людей к проблеме безопасности ИИ, и для этого нужно распространять информацию. Вы можете смотреть видео, высказывающие разумные опасения насчёт ИИ, ставить лайки, комментировать и делать репосты в своих социальных сетях. Это поможет алгоритмам Ютуба или других платформ понять, что видео стоит внимания и его нужно продвигать среди большого количества зрителей.

2. Получите необходимые знания.

В Интернете есть довольно много бесплатных курсов, статей и книг, посвященных искусственному интеллекту и его безопасности. Например <https://bluedot.org/courses/>.

Важно понимать происходящее, чтобы делать более правильные и рациональные решения, а также быть способным отстаивать свое мнение перед другими людьми.

3. Распространяйте знания.

Вы можете делиться информацией о рисках ИИ на вашей странице в соцсети, завести для этого отдельный блог на Medium или YouTube, или же начать с малого: своего круга общения.

Если вы понимаете, насколько важна проблема ИИ для будущего нашей цивилизации, в вас может найтись достаточно энергии чтобы запланировать встречу с дорогим вам человеком и искренне обсудить с ним эту тему.

Тем самым вы сможете создать большее количество осведомлённых людей, принимающих более верные решения.

Вы можете также организовывать встречи со своими местными политиками либо писать им письма (как личные, так и открытые) с разъяснением рисков ИИ и просьбами / предложениями управленческих решений.

4. Свяжите свою профессию с ИИ безопасностью.

Многие виды деятельности можно напрямую или косвенно связать с устранением ИИ-рисков.

Если у вас есть знания в математике, программировании или тем более нейросетях — вы можете направить свои навыки на решение технических проблем, таких как alignment или explainability. Мы рекомендуем также воздержаться от участия в проектах, целью которых прежде всего является участие в гонке — то есть ускорение ИИ-прогресса без соответствующего ускорения безопасности.

Если вы связаны со сферой биологии, химии или медицины вы можете, например, заняться биологическими рисками, обеспечивать безопасность биолaborаторий и автоматизированных исследований в этих областях.

Если вы находитесь в сфере социальных или некоторых гуманитарных наук, вы можете заниматься принятием или лоббированием политических решений, необходимых для эффективной ИИ-регуляции. Это очень важная область.

Если ваша профессия не была упомянута выше, это не значит, что вы не можете помочь. Вполне возможно, что вы сможете сделать большой вклад в дело — пожалуйста, используйте возможность бесплатной карьерной консультации тут:

<https://80000hours.org/>

5. Использовать свой голос избирателя. (Свяжитесь со своим конгрессменом, если вы в США. Вы имеете большое влияние на всю индустрию ИИ, просто обладая американским гражданством).

6. Участвуйте в публичных обсуждениях законов. (Это полезно например в рамках диалогов ООН или европейского AI Act).

7. Участвуйте в акциях протеста и мирных демонстрациях.
Подписывайте петиции и открытые письма.

8. Не делайте хуже.

Я рекомендую:

- Не участвовать в создании или аннотации данных для обучения новых ИИ моделей. Это почти всегда ускоряет прогресс.
- Не работать на крупные ИИ компании, стремящиеся к максимизации прибыли. Редким исключением может быть действительно хороший проект по безопасности ИИ.
- Обдумывайте свою научную деятельность, публикации и высказывания — особенно в долгосрочной перспективе. Наши решения часто могут иметь двойной эффект, и в ИИ-сфере важно не допустить ущерб.
- Используйте ИИ ответственно: не раскрывайте ему личную информацию, не давайте доступ к банковским счетам или аккаунтам.
- Однако не стоит также бездействовать, опасаясь за каждое свое действие как потенциально опасное. Главное подходить к решениям ответственно.