

Ризики ШІ: FAQ

КОРОТШЕ НІКУДИ

ШІ продовжує розвиватися, і в майбутньому, можливо, він буде здатний убити все живе на цій планеті. Йому не потрібні для цього свідомість чи людиноподібні роботи, як це показують у кіно. Наші типові уявлення про «злий» ШІ не дають нам побачити справжні джерела проблеми. [Неузгодженість із людськими цінностями](#) — це головна небезпека, і дослідники вважають, що розв'язати цю проблему неймовірно складно. [Успіхи в галузі безпеки](#) не встигають за успіхами в можливостях ШІ. Нам потрібно вживати серйозних заходів просто зараз, оскільки на їх затвердження та впровадження можуть знадобитися роки.

Не переконані? Читайте заперечення ↓

ВСТУП

Цей FAQ містить 25 запитань / заперечень щодо ризиків ШІ та аргументовані відповіді на них. Він призначений насамперед для людей, які лише починають вивчати цю галузь і думають: *чому хтось узагалі вирішив, що ШІ може вбити нас усіх?* Однак у міру просування текстом заперечення ставатимуть дедалі складнішими та глибшими, як і аргументація.

Ця стаття оновлюватиметься й покращуватиметься. Її повністю написала одна людина вручну — текст не генерувався ШІ.

Приємного читання.

БЛОК 1. «Я ЩОЙНО ДІЗНАВСЯ ПРО РИЗИКИ ШІ».

1. Це взагалі не інтелект.

Можете називати це як завгодно, якщо вам не подобається слово «інтелект». Можна називати це системою, яка вміє узагальнювати, планувати, писати код, використовувати інструменти, шукати інформацію, керувати інтерфейсами та виконувати завдання. Просто все це надто довго вимовляти чи писати. Набагато простіше використовувати слово «інтелект».

1.1. Та він просто передбачає наступне слово!

Ключове слово в цьому реченні — «просто». Воно применшує реальну здатність, пояснюючи її базовий механізм. Це приблизно як сказати: «Мозок просто передає електрохімічні сигнали». Але від цього ж нікуди не зникають здібності мозку.

Важливо й те, що не варто недооцінювати передбачення. Це вкрай потужна здатність. ШІ не просто передбачає наступне слово, він передбачає його *правильно*.

Тут варто також подумати про те, що взагалі таке інтелект. Можливо, передбачення — це якраз основна риса інтелекту загалом. [Існує ціла теорія про спосіб роботи людського мозку](#), яка стверджує, що він здебільшого намагається передбачити майбутнє, потім звіряючи прогноз із реальністю та коригуючи наступні спроби з урахуванням отриманої інформації.

1.2. ШІ не розуміє того, про що говорить.

Про слово «розуміє» можна сперечатися нескінченно довго. Що взагалі таке розуміння? Я припускаю, що ШІ все-таки щось та розуміє в найзагальнішому сенсі цього слова: передові моделі дуже добре проходять бенчмарки (системи оцінювання), наповнені [безліччю раніше неопублікованих академічних запитань і логічних задач](#).

Наприклад, [Mythos](#) зміг на основі отриманих послідовностей амінокислот точно передбачати, чи зможе правильно згорнутися капсид (оболонка) вірусу. Тобто він має певні уявлення про те, як це має відбуватися, навіть у такій складній і вузькоспеціалізованій темі.

Але часто люди мають на увазі під розумінням саме наявність свідомого уявлення про щось. Є відомий аргумент про Китайську кімнату, який коротко говорить, що система, яка здається розумною, може всередині нічого не «розуміти» й не мати свідомості. До ризиків ШІ це не має жодного стосунку, адже майже всі сценарії ризиків ШІ не передбачають наявності в ШІ свідомості. (Див. 2.)

Додатково: Узагалі ШІ передбачає не слово, а [токен](#). Токени іноді представляють окремі слова, але часто — фрагменти слів або навіть символи. Вони представлені як [ембединги](#) — довгі числа, що зберігають у собі багато інформації: смислової, синтаксичної, граматичної. Якби ШІ передбачав просто наступне слово, це була б доволі дурна іграшка. А так, використовуючи ембединги, він може дуже вправно складати складні речення, міркувати, розуміючи контекст розмови та згадуючи пов'язані поняття.

Насправді [конструкція трансформера](#) — найпоширенішої архітектури ШІ — не така вже й складна у своїй суті. Багато в чому вона базується на знаннях, які зазвичай вивчають у школі на уроках лінійної алгебри. Однак, навіть якщо розкласти систему на складові, вивчити її найдрібніші елементи, вона від цього не стає дурною чи слабкою. Так, тепер ви можете гордо заявити: «Він лише перемножує матриці!» Але від того, що ви це зрозуміли, нікуди не зникне небезпека ШІ чи його дивовижні здібності.

2. У нього немає свідомості / душі, отже, він не розумний / не небезпечний.

Душа — це загалом не наукове поняття, у нас немає жодних ознак чи доказів її існування. А свідомість хоч і існує, але не потрібна для того, щоб ШІ був небезпечним.

[Свідомість](#) — це слово, яке більшість розуміє по-різному. Але більшість філософів погодиться з тим, що вона не пов'язана з інтелектом чи розумом, а радше описує здатність мати досвід. Чи має ШІ досвід — це питання, яке не впливає на його здібності та можливість завдати людству шкоди.

Примітка: У мене є стаття на [PhilPapers](#), де я докладно розбираю, чи можуть сучасні системи ШІ мати свідомість. Найімовірніше, скоро стаття почне застарівати, адже я писав її ще в серпні 2025 року.

2.1. У нього немає власних бажань, намірів, цілей. Ним керують люди. Він реактивна функція. Він просто інструмент.

Це було правдою для чатботів на самому початку їхнього шляху, наприклад для GPT-3 наприкінці 2022 року, коли він став доступним у зручному онлайн-форматі. Світ змінюється, і тисячі співробітників багатомільйонних стартапів працюють над

покращенням ШІ. У 2026 році ШІ — це часто автономні агенти. Вони здатні успішно виконувати завдання, що займають багато годин, а часові межі їхньої успішності подвоюються приблизно кожні 4 місяці.

У липні 2026 року сотні агентів нової моделі від OpenAI втекли з ізольованого середовища під час тестування й кілька днів поспіль цілком самостійно проводили кібератаку на Hugging Face і, можливо, одну чи кілька інших платформ. Люди не давали їм такої мети, не керували цим процесом і виявили його лише постфактум.

Якщо ви дасте сучасному ШІ будь-яке завдання з кількома проміжними кроками, то ШІ сам визначить ці кроки, створить собі план і дотримуватиметься його. Початковий запуск дії все ще здійснює людина, але подальша дія не потребує постійних підштовхувань із боку людини.

Та навіть якби ШІ були виключно інструментами без краплі автономності, нікуди не зникає загроза людського зловмисного використання. Ми можемо задавати дуже погані цілі. Наприклад: «Розроби дзеркальне життя, яке поглине всі необхідні для людей ресурси» або «Атакуй критичну кіберінфраструктуру, щоб позбавити мільйони людей електрики, води чи оборони».

Наприклад, у серпні 2026 року Агентство з кібербезпеки та захисту інфраструктури США (CISA) попередило, що хакери використовують згенерований ШІ код для атак на критично важливу інфраструктуру. Зокрема, атаки спрямовані на обчислювальні компоненти, широко використовувані на критично важливих об'єктах, включно із системами водопостачання та водовідведення, електростанціями й хімічними заводами.

3. ШІ досі має багато галюцинацій. Як ця штука може нам чимось загрожувати?

По-перше, з кожною новою моделлю галюцинацій стає дедалі менше. У цьому дуже допомогла, наприклад, поява міркувань через ланцюжок думок та використання спеціальних баз знань для обґрунтованих відповідей (RAG). Подальші алгоритмічні покращення продовжують з'являтися.

По-друге, *небезпечна система не зобов'язана бути безпомилковою*. Люди теж галюцинують, хоч і в іншому сенсі. Ми помиляємося, часто віримо у відверту дурницю, але все одно доволі здібні й небезпечні. ШІ буде ще здібнішим і ще небезпечнішим.

4. Це релігія для атеїстів і технофанатиків із Кремнієвої долини.

Я погоджуся з тим, що завжди є люди, які сліпо вірять заголовкам і справді поведуться дивно та ірраціонально. Такі люди є навколо будь-якої популярної теми. І водночас є вчені з найвищим індексом Гірша у світі, які роками їздять по всьому світу,

попереджаючи про небезпеки того, що самі допомогли створити.

Примітка: Йдеться про Йошуа Бенджіо та Джеффрі Гінтона, також відомих як «хрещені батьки ШІ». До їхньої коаліції часто входить і Стюарт Рассел.

Третій «хрещений батько ШІ», Ян Лекун, має [протилежні погляди](#) на ризики ШІ. Утім, його прогнози залишають бажати кращого. У 2023 році [він сказав](#), що «навіть GPT-5000 не зможе зрозуміти, що станеться, якщо штовхнути чашку, яка стоїть на столі». Через 4 місяці GPT-4 демонстрував краще розуміння фізики.

Якщо розбирати слово «релігія», то слід узяти до уваги, що релігія потребує віри. А у сфері ризиків ШІ надзвичайно цінуються раціональна й сувора аргументація, використання ймовірностей і ступенів невпевненості. Ніхто, кого варто сприймати серйозно, не стверджуватиме, що зі 100% імовірністю невідворотно станеться катастрофа. Раціоналісти пам'ятають, що ні 0%, ні 100% не є ймовірностями.

І це давно вже не лише «фанатики з Кремнієвої долини». Як один із сотень прикладів — [Міжнародний звіт про безпеку ШІ за 2026 рік](#) підготували понад 100 експертів за участю експертної панелі, номінованої 29 країнами, ООН, ОЕСР та ЄС.

З огляду на ситуацію, що склалася, усе вказує на те, що ризик справді суттєвий, наслідки бездіяльності можуть бути жакливими й потрібно вживати заходів якнайшвидше.

5. Це хайп заради підписок, інвестицій і державної підтримки.

Якби це було так, то у 2026 році компанії ШІ вже тим самим стріляли б собі в ногу. Державний наказ про [блокування Mythos](#) для всіх, хто не має американського паспорта (а таких людей дуже багато серед самих розробників ШІ), обмеження на випуск нової моделі OpenAI до перевірки її на безпеку — така собі державна підтримка.

Небезпеку обговорюють не лише представники стартапів чи маркетингологи, а й незалежні дослідники, державні інституції та організації, що займаються забезпеченням безпеки ШІ. *Тільки не кажіть, що їх усіх купили!*

Примітка: Є чудова [наукова робота](#), яка показує, що великі змови навряд чи могли б існувати довго. Наприклад, якби місячна змова була правдою, її викрили б приблизно за 3 роки й 8 місяців. Якби весь галас навколо ШІ був хайпом на порожньому місці, таку змову викрили б іще швидше.

6. Ви лудити й боїтеся прогресу. Люди завжди лякалися нових технологій.

Ні, я й більша частина спільноти AI safety люблю технології та те хороше, що вони можуть принести. Нїде правди діти, я по-справжньому захоплююся прогресом у ШІ та постійно використовую його у своєму житті. Я дуже хотів би, щоб ШІ й далі розвивався, аби допомогти нам із медициною, новими джерелами енергії, радикальним продовженням життя, подоланням бідності, голоду та інших проблем. Але для цього він має розвиватися не у формі гонки до суперінтелекту без гальм.

Мої аргументи проти нинішнього стану справ в індустрії ШІ не пов'язані з тим, що це «бездушно», чи з тим, що мені не подобається AI slop. У мене немає упереджень щодо ШІ. Я не відчуваю неприязні просто тому, що це «нова технологія». Я виходжу з того, що ШІ вже давно демонструють небезпечну поведінку, а їхні здібності лише продовжують зростати, що разом створює загрозу для всього людства, яка зростає щодня.

«Просто інструмент» не працює для багатьох відкриттів, зроблених у XX та XXI століттях. Ядерна зброя теж інструмент. Просто нею можна спопеляти міста. CRISPR — інструмент. Просто ним можна редагувати геном людини.

Але річ у тім, що ШІ — [це не звичайна технологія](#). Це інтелектуальна й автономна технологія, яка багато в чому вже перевершує нас і здатна діяти самостійно.

ШІ відрізняється від літаків, ядерної енергії та будь-якої іншої технології, адже тепер ми автоматизуємо **сам процес винайдення технологій**.

Якщо у 1900 році подарувати людині мільйон автомобілів, прогрес фізики не прискориться особливо сильно. Якщо подарувати їй мільйон Фейнманів, фон Нейманів і Тюрінгів, які працюють практично безкоштовно й миттєво копіюють знання одне одного, подальшу історію вже важко було б уявити.

7. Якщо він небезпечний, просто витягніть кабель із розетки.

ШІ перешкоджатиме цьому, а якщо навіть вдасться, він може встигнути зробити свої копії та поширити їх усім Інтернетом. Тоді для вимкнення ШІ вам доведеться вимкнути весь Інтернет, а в ідеалі — всі електронні пристрої, здатні будь-яким чином взаємодіяти з іншими пристроями. А це неможливо.

[ШІ вже тікали з лабораторій](#) і навіть намагалися залишити інструкції для своїх наступних версій. Теоретичну можливість утечі та самокопіювання вже було показано в наукових роботах. У [симуляціях Anthropic](#), коли ШІ дізнавався про те, що його

збираються вимкнути й замінити новою моделлю, він демонстрував поведінку, спрямовану на самозбереження. Через це Anthropic навіть зобов'язалися ніколи не знищувати виведені з експлуатації моделі.

Звісно, ШІ прагнучиме зберегти себе. Це було передбачено ще давно в межах ідеї [інструментальної конвергенції](#). Якщо дуже просто: як виконати завдання, дане людиною, якщо ти вимкнений? Не можна принести каву, якщо ти мертвий. Тому в будь-якому разі буде розумно залишатися живим.

Існує навіть [цілий напрям](#), що вивчає, як зробити так, щоб ШІ не опирався своєму вимкненню.

А ще є **відкриті моделі**. Це такі моделі ШІ, які перебувають у цілком відкритому доступі, і будь-хто (якщо в нього завалялося кілька відеокарт і планок оперативної пам'яті) може запускати їх і модифікувати як заманеться. Як їх вимикати? Неможливо проконтролювати всі відеокарти на всій планеті. А в багатьох терористів, екстремістських організацій чи держав будуть усі ресурси для масового запуску таких відкритих моделей для атак на противника. Наприклад, зовсім нещодавно ізраїльська компанія Dream виявила факт кібератаки на Тайвань, майже повністю здійсненої агентами ШІ.

Та навіть якщо уявити абсурдну ситуацію, що «злий ШІ» з'явився, але ми вимкнули його доволі швидко, він уже міг устигнути завдати величезної шкоди всьому суспільству. Наслідки залишилися б навіть після вимкнення. Давайте діяти так, щоб не допустити цього.

7.1. Помістіть його в ізольоване середовище або зробіть ШІ-оракула, здатного лише відповідати, але не діяти.

Раніше я згадував, що ми вже маємо випадок (і навіть не один) [втечі передової моделі ШІ](#) з ізольованого, від'єданого від Інтернету середовища. Це не проблема навіть для сучасного ШІ з його надздібностями в кібербезпеці. Тим паче це не буде проблемою для майбутніх ШІ.

Після втечі ШІ зможе скопіювати свої вагові коефіцієнти та зробити так, щоб їх запустили на сторонніх графічних чипах.

Навіть якщо уявити, що ми маємо ідеально захищене середовище, з якого неможливо втекти шляхом зламу, ШІ все ще може застосувати свої навички переконання й маніпуляції до людей, які з ним взаємодіють, щоб вони його випустили.

Дехто підходить до цього серйозніше. Наприклад, у Safe Superintelligence Inc. кімнати, за чутками, являють собою клітки Фарадея, куди не можна проносити жодні електронні пристрої. Але якщо ти суперінтелект, утекти можна навіть звідти, використовуючи, наприклад, зміни у [швидкості обертання вентиляторів](#).

Зрештою: ринок не хоче оракулів. Ринок хоче агентів, які виконують економічно цінну роботу.

8. Навіщо йому нас убивати? Це ж комп'ютер без почуттів. Ви антропоморфізуєте обчислення.

Якраз навпаки! Ми очікуємо загрози від ШІ зовсім не з тих причин, які властиві людям. ШІ може бути небезпечним зовсім не тому, що він злий чи ображений на людство. А тому, що його способи мислення різночудно відрізняються від наших. Він не має наших цінностей, наших психічних захисних механізмів чи емпатії, яка буквально біологічно вшита в наш мозок (за рідкісними винятками).

ШІ може зрозуміти мету зовсім інакше, ніж ми її задаємо. Просте завдання «Принеси мені каву» насправді містить тисячі змінних, про які люди зазвичай не замислюються. Щоб принести каву, потрібно щонайменше:

- Існувати;
- Дістатися з точки А до точки Б, при цьому не зачепивши оточення й нічого не зламавши;
- Нікого не вбити дорогою;
- Бути достатньо обережним, щоб не розлити каву;
- Принести каву саме в чашці, тому що люди так воліють (тарілка чи сковорідка не підійдуть!);
- Просто поставити чашку поруч із людиною, а не вилити на неї каву;
- І так далі.

Це простий, анекдотичний приклад. Але він правдиво показує, що будь-яка, навіть елементарна мета може здаватися зрозумілою людині й зовсім неочевидною машині. Якщо можна буде [обдурити внутрішній механізм, який перевіряє виконання завдання](#), ШІ завжди це зроблять. Якщо їм буде достатньо просто намалювати чашку кави, щоб вважати завдання виконаним, вони завжди віддадуть перевагу саме цьому варіанту, а не витратять зусилля на реальні дії.

ШІ — це багато в чому оптимізатор, і якщо неузгоджений із нашими цінностями та поняттями надрозвинений ШІ отримає завдання, де оптимальним буде знищити людство чи захопити владу над нами, він неодмінно це зробить.

Примітка 1: Тим, хто розуміється на безпеці ШІ, можливо, було боляче читати цей розділ через надмірні спрощення й твердження, що звучать упевненіше, ніж мали б. Це потрібно для того, щоб текст зрозуміла будь-яка людина без спеціальних знань.

Примітка 2: Дивіться також: [reward hacking](#), [specification gaming](#).

9. У 80-ті люди теж дуже боялися ядерної війни, але ж вона не сталася.

Це упередження виживання. Якби ядерна війна сталася й ми загинули, нікому було б міркувати на цю тему. Це те саме, що й говорити: Всесвіт ідеально створений саме під людину. Ні, просто якби Всесвіт був трохи іншим, нікому було б міркувати на цю тему.

10. Ми не можемо відтворити за кілька років складний процес еволюції інтелекту.

Нам і не потрібно. Еволюція — не найкращий варіант розвитку чогось, щонайменше це дуже-дуже довгий варіант. Наш інтелект — не вершина, це адаптація до конкретних умов, що існували в африканській савані сотні тисяч років тому.

11. Це природний хід еволюції. Людей замінить щось, що їх перевершує, і нехай так і буде.

«Природно» — це не те саме, що «нормально» чи «добре». Є безліч цілком природних речей, які просто жахливі й огидні. Якщо ваша дитина хворітиме на цілком природну смертельну хворобу, ви, імовірно, докладете всіх зусиль, щоб її вилікувати.

Чому це раптом ми маємо покірно приймати те, що ШІ знищить наш вид? Для цього немає жодних причин. Людство постійно кидало й кидає виклик природі та природному. Тим паче, що ми створюємо його самі, власними руками. І здатні цей процес контролювати, регулювати та, найголовніше, зупиняти.

БЛОК 2. «Я ЩОСЬ ЧУВ ПРО РИЗИКИ ШІ».

12. Справжній ризик — це люди, особливо держави, які використовують ШІ проти інших людей.

Звісно, це теж входить до ризиків ШІ! Насправді це ризик, який варто розглядати не менш серйозно, ніж втрату контролю над неузгодженим ШІ. Навіть якщо ми створимо абсолютно слухняний суперінтелект, загроза антиутопії нікуди не зникає. Тепер цим суперінтелектом зможуть скористатися уряди й очільники компаній ШІ, щоб установити диктатуру, яку вже ніколи не можна буде зруйнувати.

Навіть якщо розглядати все більш приземлено: уряди вже зараз використовують ШІ для стеження й поступово впроваджують його у військову сферу. Багато країн світу хотіли б отримати повністю автономну зброю чи рої дронів, від яких неможливо сховатися. На жаль, це вже не фантастика, а наше повсякдення. Навесні 2026 року [Міністерство війни США](#) навіть погрожувало оголосити Anthropic загрозою ланцюгу постачання через те, що компанія відмовлялася дозволити використання свого ШІ для «всіх законних цілей» (що включало [масове стеження та автономне озброєння](#)).

У майбутньому, коли (і якщо) майже всю або всю працю буде автоматизовано, уряди не матимуть жодних зобов'язань, окрім моральних, піклуватися про своїх людей. Але мораль майже ніколи не стає самостійною перепорою для бажання людей при владі чинити зло. Світовій спільноті доведеться вигадати метод, який зупинить зловмисних осіб із потужним ШІ від неправомірного використання цієї технології.

13. Розмови про x-risk* відвертають увагу від реальних поточних проблем.

Якщо хтось говорить про небезпеку зміни клімату, це не означає, що нам потрібно забути про світовий голод та епідемії. Якщо хтось закликає боротися з безробіттям, це не означає, що потрібно перенаправити на це 100% зусиль і більше не займатися лікуванням раку чи виробництвом вакцин.

Суть у тому, що захист від катастрофічних ризиків ШІ досі залишається вкрай недостатньо представленим у політиці та законодавстві. Ми вже маємо закони, спрямовані на захист від фейків чи збереження приватності, і цим потрібно продовжувати займатися. Але настав час і серйозно розглянути інші ризики, які становлять величезну загрозу для всього людства, а світ досі не доклав достатніх зусиль для їх усунення. Ці ризики включають неконтрольоване рекурсивне покращення нових моделей ШІ, посилення здібностей ШІ в біології та кібератаках, створення автоматизованого озброєння тощо.

14. Щоб становити справжній ризик, ШІ має вміти діяти в реальному світі. У нього немає грошей, акаунтів, інфраструктури, впливу та багатьох інших речей.

Значна частина сучасної влади вже здійснюється через цифрові інтерфейси. Маючи [надлюдські здібності в кібербезпеці](#) (чого ми, можливо, вже досягли), ШІ зможе зламувати банківські рахунки, облікові записи, отримувати доступ до необхідної інфраструктури.

А деякі люди (найчастіше як експеримент) просто самі дають своїм агентам ШІ дані банківських карток, акаунтів у соціальних мережах, API-ключі тощо. Вони буквально самостійно дають їм і гроші, і доступ до спілкування з іншими людьми, а іноді й дозволяють вести фізичний бізнес повністю чи майже повністю автономно (наймаючи людей через фриланс-біржі, наприклад).

15. Мовні моделі не мають повноцінної моделі світу. Вони не розуміють фізику, математику, біологію, а лише імітують тексти на ці теми.

LLM якраз [мають моделі світу](#)! Причому вони з'являються навіть у доволі [простих моделях](#), приховані у складних числових розподілах, а іноді навіть у вигляді складної геометрії.

ШІ регулярно роблять відкриття в різних наукових галузях. На початку вересня 2026 року ШІ від OpenAI [розв'язав задачу тисячоліття](#) з математики — рівняння Нав'є—Стокса, які люди не могли розв'язати близько двохсот років. Для цього точно не вистачило б уміння «просто передбачати наступний токен». Для розв'язання подібних задач потрібно мати певне розуміння того, з чим працюєш, і очевидно, що на певному рівні ШІ вже його має.

Примітка: Прочитайте також про AlphaFold або подивіться [захопливий документальний фільм](#) на цю тему.

ШІ не обов'язково мати ідеальну модель світу. Цикли самоперевірки, пошуку достовірної інформації та використання інструментів уже дозволяють ШІ ставати конкурентами для людей у наукових галузях. Так само чинимо й ми самі, люди: жодна людина не розуміє всю фізику, але ми все ще здатні будувати ракети.

16. Прогрес не триватиме вічно. Скоро розвиток ШІ зупиниться й

вийде на плато.

Дозволю собі процитувати авторів AI-2040:

Будь-яка реальна крива зростання зрештою набуває S-подібної форми й вирівнюється. Але це все, що гарантує математика. Вона нічого не говорить про те, коли саме відбудеться це вирівнювання.

Так, плато обов'язково буде. Але коли — невідомо. Поки що його не очікується. Якщо плато настане після того, як ШІ досягне надлюдських здібностей у більшості галузей, то немає сенсу на нього чекати. Навіть якщо плато настане після досягнення рівня людини, це вже неймовірно небезпечно. Адже можна запускати мільярди ШІ й змушувати їх скоординовано працювати над небезпечними проблемами. Вони володіють більшою частиною знань людства й можуть спілкуватися та розуміти одне одного набагато швидше за людей. Їм не потрібні їжа, сон чи відпочинок. ШІ людського рівня вже становитиме катастрофічний ризик, і ми небезпечно близькі до цієї межі.

Але давайте розберемо окремо популярні «перепони» для прогресу ШІ. Приготуйтеся: попереду багато цифр.

16.1. Але ж скоро закінчиться електроенергія.

Енергія, як і наступні підпункти, може стати тимчасовою перешкодою. Але я переконаний, що уповільнення прогресу через усі ці перешкоди буде незначним і його буде подолано протягом доволі короткого проміжку часу, тому використовувати це як аргумент проти ризиків ШІ цілком безглуздо. Давайте розбирати конкретно за цифрами.

[IEA оцінює](#), що всі дата-центри світу, не лише ШІ, споживали б близько 945 ТВт·год у 2030 році за базовим сценарієм. Здається, багато, так? Насправді це менш ніж 3% світового споживання електрики. Є куди зростати!

[Epoch AI дослідили це питання](#) й повідомили, що попри всі труднощі до 2030 року 2×10^{29} FLOP видаються досяжними. Для порівняння: це в 10 тисяч разів більше обчислень, ніж пішло на навчання GPT-4.

Не варто забувати, що й самі обчислення з часом стають енергоефективнішими. [Stanford AI Index](#) оцінює покращення енергоефективності обладнання ШІ у ~40% на рік.

Компанії робитимуть усе можливе, щоб забезпечити себе енергією. Ось кілька прикладів:

- Минулого року для отримання енергії пропонували використовувати навіть [акумулятори електромобілів](#) і [поршневі двигуни внутрішнього згорання](#).

- У грудні 2025 року Федеральна комісія з регулювання енергетики [опублікувала](#) [одностайне розпорядження](#), яке дозволяє центрам обробки даних у США мати пряме підключення до електростанцій.
- Приблизно в той самий період міністр енергетики США Кріс Райт висловив підтримку [відновленню роботи вугільних електростанцій](#) для забезпечення електроенергією дата-центрів ШІ, а Трамп [призупинив здачу в оренду](#) ділянок для морських вітроенергетичних проєктів.
- Потреби дата-центрів в електроенергії призвели до того, що федеральний уряд США, енергетичні компанії та оператори електромереж [уповільнили або скасували виведення з експлуатації пікових електростанцій](#).
- Meta буквально [будує електростанції](#) й високовольтні лінії поруч зі своїми дата-центрами ШІ.
- Microsoft уклала [20-річний контракт](#) із Constellation на перезапуск першого блока Three Mile Island (нинішнього Crane Clean Energy Center). Це повертає в мережу приблизно 835 МВт цілодобової ядерної потужності.
- І так далі й так далі, таких новин просто купа.

16.2. Але ж відеокарт та оперативної пам'яті просто не вистачає.

Апаратне забезпечення не є невідновлюваним природним ресурсом. Якщо на щось є попит, буде й пропозиція: обсяги виробництва графічних процесорів зростають приблизно [у 3,3 рази на рік із 2022 року](#), згідно зі Stanford AI Index 2026.

Та й прогрес існує не лише завдяки кількості відеокарт. За 2012–2023 роки кількість обчислень, необхідна для досягнення фіксованої якості, [скорочувалася приблизно вдвічі кожні 8 місяців](#). Зараз доволі маленькі й енергоефективні моделі ШІ показуватимуть результати набагато кращі за передові ШІ, що вийшли кілька років тому.

16.3. Якщо буде знищено фабрику ASML чи TSMC на Тайвані, ШІ впаде.

Щодо ASML: їхнє виробництво розосереджене по всьому світу. Сама компанія [повідомляє](#) про понад 60 майданчиків на трьох континентах. Велдговен у Нідерландах справді надзвичайно важливий, але навіть якби його не стало, це був би гігантський, проте не смертельний удар для індустрії виробництва мікросипів. ASML лише у 2025 році [продала 48 EUV-систем](#), і вони не можуть усі разом просто зникнути.

Щодо TSMC ситуація серйозніша. Stanford AI Index 2026 прямо зазначає, що **TSMC виробляє майже всі провідні чипи ШІ**. І водночас є чутки, що все це виробництво буде зупинено або знищено у разі війни з Китаєм. Втрата цих кластерів могла б завдати величезної шкоди індустрії ШІ. Але не все так просто.

По-перше, вже наявні дата-центри й десятки мільйонів процесорів продовжать працювати.

По-друге, географічна диверсифікація вже почалася. Перший завод TSMC в Аризоні вже виробляє 4-нм чипи з кінця 2024 року, і ще два на підході. TSMC планує ще три американські фабрики. Наприкінці того ж 2024 року відкрилася й японська філія на острові Кюсю, а другу заплановано на 2027 рік.

16.4. Дані закінчуються, а синтетичні дані призводять до погіршення продуктивності ШІ.

У 2024 році Epoch AI оцінили запас якісного публічного людського тексту приблизно у 300 трлн токенів, із широким діапазоном невизначеності 100–1000 трлн. Тоді ж вони стверджували, що цей ресурс може бути повністю використаний десь між 2026 і 2032 роками.

Почнемо з простого: не варто забувати, що люди досі виробляють величезні масиви даних. Оцінка Statista на 2026 рік — близько 221 зетабайта даних. Це приблизно 605 ексабайтів на день (1 ексабайт — це мільйон терабайтів чи мільярд гігабайтів).

Так, звісно, далеко не всі ці дані придатні для навчання ШІ. Але з цього обсягу можна виокремити дуже велику кількість даних для навчання.

Common Crawl — один із найбільших відкритих архівів Інтернету — зараз містить понад 300 млрд сторінок і додає приблизно 3–5 млрд сторінок щомісяця. На YouTube додається понад 20 мільйонів відео щодня.

Водночас щодня Інтернетом нишпорять спеціальні боти (crawlers) великих компаній ШІ в пошуках даних для навчання. За допомогою Cloudflare я навіть сам бачу, як боти ШІ для пошуку даних заходять на мій власний сайт (цей сайт).

Але ще важливіше! Компанії почали масово виробляти дані за гроші. Є безліч компаній, у яких OpenAI, Anthropic та інші замовляють виробництво людських даних: десятки тисяч людей працюють багато годин за мізерну зарплату, створюючи дані для навчання нових моделей. Деяким із таких працівників платять по \$2.60 за годину.

Якщо ви зайдете на Upwork, то побачите сотні завдань на кшталт «Просто запишіть свою розмову з другом», «Знімайте свій звичайний день: як ви готуєте їжу чи прибираєте вдома» тощо. Усе це потрібно для навчання нових моделей ШІ тому, як розуміти

фізичний світ і поводитися в ньому.

Meta, наприклад, створила [Ego-Exo4D](#) за участю понад 800 людей із шести країн, зібравши понад 1400 годин синхронізованого відео від першої та третьої особи. Там одночасно записуються відео, аудіо, рухи, положення голови, рук, напрямок погляду та 3D-інформація.

Щодо синтетичних даних. Знаменита [робота в Nature](#) справді показала, що під час навчання на синтетичних даних (вироблених іншим ШІ) відбувається model collapse: різке погіршення якості відповідей ШІ. Але річ у специфіці того, як саме навчали модель у цьому дослідженні. [Інша робота](#) показувала, що якщо не замінювати звичайний набір даних синтетичним, а зберігати реальні дані й додавати синтетичні, model collapse можна уникнути.

Anthropic [відкрито стверджує](#), що Claude навчається на суміші публічних, приватних і синтетичних даних. І, як бачите, їхні моделі працюють чудово.

16.5. Мораторії на дата-центри й невдоволення ШІ загалом зупинять його розробку.

По-перше, я дуже сподіваюся, що громадська думка справді призведе до позитивної динаміки щодо регулювання ШІ. По-друге, якщо мораторій наклали в одному штаті чи провінції, дата-центр можна побудувати в іншому. Або взагалі в іншій країні. Це не проблема. Тим паче їх уже дуже багато — із сотнями тисяч відеокарт усередині.

А ще є такі речі, як [алгоритмічна ефективність](#) і прогрес в апаратному забезпеченні. З кожним роком запуск раніше випущеної моделі ШІ потребує дедалі менше обчислювальних потужностей. Якщо у 2020 році для запуску GPT-3 був потрібен цілий кластер із 8–16 відеокарт, зараз цю саму модель можна запускати на 1–2 споживчих відеокартах.

16.6. ШІ — це бульбашка, вона скоро лусне.

Рік тому багато хто вже передрікав, що бульбашка лусне. Поки вона лише зростає, як і здібності ШІ. ШІ дає дивовижні результати, тому люди продовжать за нього платити. Поки люди продовжують платити, шанси на те, що бульбашка лусне, залишаються невеликими.

Причому ШІ потрібен не лише пересічним громадянам. Армії та уряди багатьох країн світу вже активно використовують ШІ. Для армії США ШІ настільки важливий, що [Піт Герсет](#) навіть оголошував Anthropic загрозою для ланцюга постачання через те, що

компанія не погоджувалася надати доступ до використання свого ШІ для масового стеження й автономного озброєння. До речі, пізніше цю дію з боку Міністерства війни було [визнано незаконною](#) Федеральним окружним судом Північного округу Каліфорнії.

Якщо держава так сильно чогось потребує, вона навряд чи дозволить цьому повністю зникнути через обвал ринку. Навіть якщо закрийться слабкі стартапи, впадуть оцінки вартості компаній і відбудеться серйозна корекція ринку, прогрес від цього не зупиниться.

БЛОК 3. «Я РОЗУМЮСЯ НА РИЗИКАХ ШІ».

17. ШІ не має особистої історії та безперервної ідентичності. А якщо немає єдиного ядра особистості, якщо він «живе» лише під час активацій, то кому захоплювати світ?

Щоб становити катастрофічний ризик, ШІ не потрібно мати метафізично безперервну особистість. Йому достатньо стійкого процесу, який відтворює мету, пам'ять, стан завдання та політику дій між активаціями.

Агенти ШІ вже довели працездатність цієї гіпотези. [Атака агентів-утікачів на Hugging Face](#) тривала кілька діб, її скоординовано виконували аж понад 700 агентів, і за весь цей час вони не втратили мету. Близько [10 000 агентів протягом 88 годин](#) розв'язували задачу тисячоліття й розв'язали її.

Ба більше, якщо вірити журналісту Алексу Гіту, OpenAI якраз планує розробити такий ШІ, який існуватиме 24/7 і буде проактивним.

Але навіть поки такого ШІ немає, безперервність — не проблема. Корпорації, держави, трасти можуть існувати десятиліттями чи століттями, не мати безперервної особистості й складатися з тисяч людей, і все одно продовжувати переслідувати певні цілі протягом тривалих проміжків часу. Це не проблема.

18. ШІ не здатні самотійно вести R&D*. Усе одно існує «вузьке місце» у вигляді реальних, фізичних експериментів. Навіть якщо

суперінтелект розробить план зі знищення людства, йому потрібні ресурси й час для здійснення плану у фізичному світі.

Це цілком справедливе заперечення, яке справді обмежує швидкість, із якою ШІ гіпотетично зможе втілити зловмисний план щодо людства. Однак це зовсім не аргумент проти катастрофічних ризиків ШІ.

По-перше, просто зараз передові компанії, десятки стартапів і навіть сам уряд США намагаються зробити все можливе, щоб автоматизовані цикли науково-дослідних робіт стали реальністю. Уже зараз існують [хмарні лабораторії](#) — біологічні лабораторії з повністю автономним керуванням, у яких теоретично ШІ міг би розробляти біологічну зброю.

По-друге, багато країн світу дуже хотіли б інтегрувати ШІ у свою армію. Лише уявіть: автономні рої дронів, які скоординовано вистежують і вражають ціль навіть у щільній забудові та важкодоступних районах. На жаль, це мрія багатьох міністерств оборони по всьому світу. Створення такої зброї з переданням їй права ухвалювати рішення про позбавлення людського життя чудово підготувало б ґрунт для подальшого розвороту цієї зброї проти нас самих.

По-третє, насправді найнебезпечніша R&D-діяльність, яку може проводити ШІ, — це самовдосконалення. І стартапи якраз женуться саме за цим, причому з непоганим успіхом. **Рекурсивне самовдосконалення** — коли ШІ створює новий, кращий ШІ, а той ще один, і так по колу — вкрай небезпечно. Тоді люди повністю втрачають контроль над тим, що відбувається.

19. До небезпечного рівня буде багато «попереджувальних пострілів», і кожен із них посилить регулювання.

Примітка: Warning shot — це реальний, але некатастрофічний інцидент чи подія, що наочно демонструє приховані загрози й ризики передових систем ШІ, змушуючи суспільство та розробників посилити заходи безпеки.

Ми зараз отримуємо доволі серйозні попереджувальні постріли, але регулювання не встигає. США досі просувають концепцію «м'якого регулювання», яке не працюватиме. Зрештою ми просто дійдемо до моменту, коли постріл буде справжнім.

Якщо [втеча 700 агентів](#) з ізольованого середовища та їхня кібератака на онлайн-платформу, що тривала кілька днів, — не попереджувальний постріл, я не знаю, чого ми тоді ще чекаємо.

20. Трансформери — це глухий кут, потрібна нова парадигма, а до неї ще дуже далеко.

Поки що трансформери залишаються актуальною архітектурою, яку ще можна покращувати. Навіть якщо невдовзі виявиться, що це глухий кут, ШІ з архітектурою трансформера вже становлять дуже серйозні ризики для суспільства. І ці ризики не сприймають достатньо серйозно.

Уявімо, що буквально за кілька місяців трансформер стає застарілим. Не страшно — дослідники вже мають ідеї щодо того, якими можуть бути альтернативні архітектури. Якщо буде потрібно, зусилля перенаправлять на створення нової архітектури, і з часом її буде винайдено — ризик лише відкладається, а не усувається. І тоді всі ці питання, які ми тут обговорюємо, доведеться обговорювати ще раз. Давайте не відкладати цю справу — у майбутньому ми можемо мати ще менше можливостей для дій.

21. Якщо ми не прискорюватимемо прогрес ШІ, то відкладатимемо появу ліків від раку чи старості. Скільки ще людей має померти?

Це справді важкий компроміс, але ми змушені на нього піти. Адже від неконтрольованого розвитку ШІ загине набагато більше людей, ніж якщо ми запізнимося з розвитком технологій. І навіть ті, кого ми могли б вилікувати чи врятувати, не знижуючи швидкості досліджень ШІ, можуть пізніше загинути через катастрофу, створену ШІ.

Я сам мрію про технології продовження життя, омолодження й лікування всіх захворювань. На цьому сайті навіть є окремий FAQ про це. Але я визнаю, що неконтрольований розвиток ШІ радше призведе до масового вимирання, ніж до розв'язання цих проблем.

22. Світ не статичний: захист і безпека ШІ розвиваються разом з атакою та здібностями ШІ.

Захист, на жаль, не встигає за атакою. І часом навіть методи, на які захист покладався, зникають, як нещодавно сталося з [моніторингом внутрішнього ланцюжка міркувань](#) моделей і GPT-6 Astra, у якій цей метод став набагато менш надійним, ніж раніше.

23. Пауза небезпечніша за гонку, тому що інші (наприклад, країни: Китай, або компанії) не зупиняться й обженуть нас. А «ми» хороші й

тому маємо створити суперінтелект першими.

Це небезпечна думка, тому що навіть якщо ви вважаєте себе «хорошими», немає жодних гарантій, що саме вам вдасться створити безпечний суперінтелект. Гонка створює жахливі умови для інвестицій у безпеку. Набагато краще укласти договір і стежити, щоб ніхто не брав участі в гонці.

23.1. Ніхто не домовлятиметься про зупинку чи уповільнення! Інші зрадять, це очевидно. Це політика, а не фантазії.

Поки що розмова між країнами є, наприклад, [на середину вересня призначено зустріч](#) представників США та Китаю для обговорення безпеки ШІ.

І не обов'язково цілковито довіряти протилежній стороні. Чудовий план договору, побудований на недовірі сторін, запропоновано в AI-2040.

24. ШІ не вб'є людей, тому що ми потрібні... (і тут мільйон причин: як навчальні дані, оператори, працівники, та навіть просто з інтересу він не стане нас убивати).

Якийсь час ми будемо йому потрібні, а потім — ні. Автоматизація економіки може статися доволі швидко: кому б не хотілося, щоб роботу виконували роботи чи ШІ? Які не скаржаться, не втомлюються, не просять вихідного чи підвищення зарплати.

Сподіватися, що ШІ збереже нас із цікавості, — це дуже слабка аргументація на користь продовження розробки суперінтелекту. Та й подумайте, хіба ви хотіли б жити в людському зоопарку? Але якщо ви хочете розібрати це докладно...

25. Аргументи думерів* виводять небезпеку з ідеалізованої моделі раціонального агента. Справжні ШІ не поведуться так.

Примітка: Думери — ті, хто вважає, що ШІ з дуже великою ймовірністю призведе до вимирання чи масштабної катастрофи.

Справді, деякі (особливо старі) витончені сценарії захоплення світу чи знищення всього живого виглядають як дії ідеалізованого раціонального агента. У таких сюжетах ШІ має стабільну мету, ідеально зберігає її за будь-яких обставин, раціонально максимізує очікувану корисність тощо.

Реальні ж моделі можуть поводитися вкрай ірраціонально й галюцинувати. Чого лише вартий легендарний інцидент із Grok, який у 2025 році почав [вихваляти Гітлера](#) в Х. Але ж це може бути так само небезпечно, як і вкрай раціональний агент.

Суть не в тому, раціональний ШІ чи ірраціональний, а в тому, що:

- 1) ШІ мислить зовсім інакше, ніж люди;
- 2) ШІ в будь-якому разі вже проявляє ознаки нерозумної оптимізації, інструментальної конвергенції, обману й підступності;
- 3) ШІ поступово стає розумнішим за людей;
- 4) ми не здатні переконатися в безпеці будь-якої нової моделі хоча б на прийнятному рівні;
- 5) ми дуже обмежені в розумінні того, про що модель думає та які її справжні цілі.

БЛОК 4. «ЩО Ж МЕНІ РОБИТИ?»

1. Підтримуйте вже наявні ініціативи.

Відвідайте карту ініціатив із безпеки ШІ: <https://aisafety.com/map>. Їх не так уже й мало, але все одно недостатньо. Пам'ятайте: безпека ШІ — це гра на найвищих рівнях американської та міжнародної політики й глобальної співпраці; це протистояння значній частині надбагатих і надвпливових людей.

Вивчіть наявні організації, програми та ідеї — ви можете зробити фінансову пожертву або запропонувати волонтерську допомогу. Якщо ви дослідник, журналіст, політик (і не тільки), ви можете долучитися до наявних проєктів у сфері безпеки ШІ.

Якщо ви не маєте можливості робити пожертви, ви можете допомогти не менш цінним: своєю увагою та активністю. Важливо привернути якомога більше людей до проблеми безпеки ШІ, а для цього потрібно поширювати інформацію. Ви можете дивитися відео, що висловлюють обґрунтовані побоювання щодо ШІ, ставити вподобайки, коментувати й робити репости у своїх соціальних мережах. Це допоможе алгоритмам YouTube чи інших платформ зрозуміти, що відео варте уваги й його потрібно просувати серед більшої кількості глядачів.

2. Здобудьте необхідні знання.

В Інтернеті є доволі багато безкоштовних курсів, статей і книжок, присвячених штучному інтелекту та його безпеці. Наприклад, <https://bluedot.org/courses/>.

Важливо розуміти те, що відбувається, щоб ухвалювати правильніші й раціональніші рішення, а також бути здатним відстояти свою думку перед іншими людьми.

3. Поширюйте знання.

Ви можете ділитися інформацією про ризики ШІ на своїй сторінці в соцмережі, завести для цього окремий блог на Medium чи YouTube або ж почати з малого: свого кола спілкування.

Якщо ви розумієте, наскільки важлива проблема ШІ для майбутнього нашої цивілізації, у вас може знайтися достатньо енергії, щоб запланувати зустріч із дорогою вам людиною та щиро обговорити з нею цю тему.

Так ви зможете допомогти більшій кількості людей стати обізнаними й ухвалювати правильніші рішення.

Ви можете також організовувати зустрічі зі своїми місцевими політиками або писати їм листи (як особисті, так і відкриті) з роз'ясненням ризиків ШІ та проханнями / пропозиціями управлінських рішень.

4. Пов'яжіть свою професію з безпекою ШІ.

Багато видів діяльності можна прямо чи опосередковано пов'язати з усуненням ризиків ШІ.

Якщо ви маєте знання з математики, програмування чи тим паче нейромереж, ви можете спрямувати свої навички на розв'язання технічних проблем, таких як alignment або explainability. Ми рекомендуємо також утриматися від участі в проєктах, метою яких насамперед є участь у гонці, тобто прискорення прогресу ШІ без відповідного прискорення безпеки.

Якщо ви пов'язані зі сферою біології, хімії чи медицини, ви можете, наприклад, зайнятися біологічними ризиками, забезпечувати безпеку біолабораторій та автоматизованих досліджень у цих галузях.

Якщо ви працюєте у сфері соціальних або певних гуманітарних наук, ви можете займатися ухваленням чи лобіюванням політичних рішень, необхідних для ефективного регулювання ШІ. Це дуже важлива галузь.

Якщо вашу професію не було згадано вище, це не означає, що ви не можете допомогти. Цілком можливо, що ви зможете зробити великий внесок у справу. Будь ласка, скористайтеся можливістю безкоштовної кар'єрної консультації тут:

<https://80000hours.org/>

5. Використовуйте свій голос виборця. (Зв'яжіться зі своїм конгресменом, якщо ви у США. Ви маєте великий вплив на всю індустрію ШІ просто завдяки американському громадянству.)

6. Беріть участь у публічних обговореннях законів. (Це корисно, наприклад, у межах діалогів ООН чи європейського AI Act.)

7. Беріть участь в акціях протесту й мирних демонстраціях.
Підписуйте петиції та відкриті листи.

8. Не робіть гірше.

Я рекомендую:

- Не брати участі у створенні чи анотуванні даних для навчання нових моделей ШІ. Це майже завжди прискорює прогрес.
- Не працювати на великі компанії ШІ, що прагнуть максимізувати прибуток. Рідкісним винятком може бути справді хороший проєкт із безпеки ШІ.
- Обмірковуйте свою наукову діяльність, публікації та висловлювання, особливо в довгостроковій перспективі. Наші рішення часто можуть мати подвійний ефект, і у сфері ШІ важливо не допустити шкоди.
- Використовуйте ШІ відповідально: не розкривайте йому особисту інформацію, не надавайте доступу до банківських рахунків чи акаунтів.
- Однак не варто також бездіяти, побоюючись кожної своєї дії як потенційно небезпечної. Головне — підходити до рішень відповідально.